

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG THÀNH PHỐ HỒ CHÍ MINH



ĐỀ CƯƠNG ĐỒ ÁN HỌC PHẦN

TÊN ĐỀ TÀI:

**HỆ THỐNG NHẬN DIỆN TẾ NGÃ TRONG NHÀ
BẰNG PHÂN TÍCH CHUYỂN ĐỘNG NGƯỜI**

Học viên thực hiện: Nhóm 2

1. Nguyễn Gia Bảo – MSSV: 2045230010
2. Nguyễn Đình Tùng – MSSV: 2045230089
3. Lê Nguyễn Tấn Đạt – MSSV: 2045230023
4. Lý Vĩnh Đức – MSSV: 2001240087

Người hướng dẫn: **TS. Phùng Thế Bảo**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG THÀNH PHỐ HỒ CHÍ MINH



ĐỀ CƯƠNG ĐỒ ÁN HỌC PHẦN
THỊ GIÁC MÁY TÍNH VÀ NHẬN DẠNG MẪU

TÊN ĐỀ TÀI:
HỆ THỐNG NHẬN DIỆN TẾ NGÃ TRONG NHÀ
BẰNG PHÂN TÍCH CHUYÊN ĐỘNG NGƯỜI

Học viên thực hiện: Nhóm 2

1. Nguyễn Gia Bảo – MSSV: 2045230010
2. Nguyễn Đình Tùng – MSSV: 2045230089
3. Lê Nguyễn Tấn Đạt – MSSV: 2045230023
4. Lý Vĩnh Đức – MSSV: 2001240087

Người hướng dẫn: TS. Phùng Thế Bảo

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CAM ĐOAN

Chúng em xin cam đoan đề án "Hệ thống nhận diện té ngã trong nhà bằng phân tích chuyển động người" là đề tài nghiên cứu độc lập do chúng em là tác giả thực hiện dưới sự hướng dẫn của TS.Phùng Thế Bảo. Đề án chưa được công bố trong bất cứ công trình nghiên cứu nào. Các số liệu và nội dung được trình bày trong đề án là trung thực, có nguồn gốc rõ ràng, hợp lệ và đảm bảo tuân thủ các quy định về bảo vệ quyền sở hữu trí tuệ.

Chúng em xin chịu trách nhiệm về toàn bộ nội dung của đề án này!

Tác giả

MỤC LỤC

MỤC LỤC	i
DANH MỤC TỪ VIẾT TẮT	ii
DANH MỤC HÌNH	iv
LỜI MỞ ĐẦU	v
CHƯƠNG 1: TỔNG QUAN ĐỒ ÁN	6
1.1 Đặt vấn đề	6
1.2 Tình hình nghiên cứu và tính mới của đồ án	7
1.2.1 Nghiên cứu liên quan.....	7
1.2.2 Tính mới của đồ án.....	9
1.3 Mục tiêu nghiên cứu.....	10
1.3.1 Mục tiêu tổng quát.....	10
1.3.2 Mục tiêu nghiên cứu cụ thể.....	10
1.4 Đối tượng và quy mô nghiên cứu.....	11
1.4.1 Phạm vi.....	11
1.4.2 Đối tượng.....	11
1.5 Nội dung và kỹ thuật nghiên cứu	11
1.5.1 Nội dung nghiên cứu	11
1.5.2 Kỹ thuật nghiên cứu.....	12
CHƯƠNG 2: DỰ KIẾN CẤU TRÚC ĐỒ ÁN VÀ KẾ HOẠCH.....	14
2.1 Dự kiến cấu trúc các nội dung nghiên cứu, thực hiện trong đồ án	14
2.2 Kế hoạch thực hiện	21
TÀI LIỆU THAM KHẢO.....	23

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Tiếng anh	Diễn giải tiếng việt
1	ADL	Activities of Daily Living	Hoạt động sinh hoạt hằng ngày
2	HAR	Human Activity Recognition	Nhận dạng hoạt động của con người
3	HPE	Human Pose Estimation	Ước lượng tư thế người
4	SVM	Support Vector Machine	Máy vector hỗ trợ
5	RBF	Radial Basis Function	Hàm cơ sở xuyên tâm
6	GCN	Graph Convolutional Network	Mạng tích chập đồ thị
7	ST-GCN	Spatial-Temporal Graph Convolutional Network	Mạng tích chập đồ thị không-thời gian
8	ME-STGCN-TA	Motion-Enhanced ST-GCN with Temporal Attention	ST-GCN tăng cường chuyển động với chú ý thời gian
9	LOSO	Leave-One-Subject-Out	Đánh giá chéo giữ lại một chủ thể làm tập kiểm tra

DANH MỤC HÌNH

LỜI MỞ ĐẦU

Té ngã ở người cao tuổi đang trở thành một vấn đề y tế - xã hội nghiêm trọng trong bối cảnh già hóa dân số toàn cầu. Theo Tổ chức Y tế Thế giới (WHO), té ngã là nguyên nhân gây tử vong do tai nạn đứng thứ hai trên toàn thế giới. Việc xây dựng một hệ thống tự động nhận diện té ngã trong nhà - nơi phần lớn các sự cố xảy ra - vì vậy có ý nghĩa thực tiễn rõ ràng đối với chăm sóc người cao tuổi, y tế cộng đồng và các dịch vụ nhà thông minh.

Đồ án này đề xuất một hệ thống nhận diện té ngã trong nhà dựa trên phân tích chuyển động người, sử dụng bộ dữ liệu GMDCSA-24. Video được chuyển thành chuỗi 33 landmark bằng MediaPipe Pose; sau đó kết hợp vị trí tương đối, visibility và các đặc trưng chuyển động. Mô hình chính là Motion-Enhanced Spatial-Temporal Graph Convolutional Network with Temporal Attention (ME-STGCN-TA), nhằm phân biệt Fall với các hoạt động ADL dễ gây nhầm trong phạm vi dữ liệu của đồ án.

Đề cương đồ án được chia thành 2 chương, gồm có:

- Chương 1: Tổng quan của đồ án.**
- Chương 2: Dự kiến cấu trúc đồ án.**

CHƯƠNG 1: TỔNG QUAN ĐỒ ÁN

1.1 Đặt vấn đề

Té ngã (fall) được định nghĩa là bất kỳ sự kiện nào mà một người mất thăng bằng và chuyển sang trạng thái không mong muốn, có thể có hoặc không dẫn đến va chạm với mặt sàn. Ở người cao tuổi, té ngã là nguyên nhân hàng đầu gây thương tích không chủ ý và tử vong. Trong hộ gia đình một người hoặc hai người – đặc biệt phổ biến ở các nước có tỷ lệ già hoá cao – hậu quả của té ngã còn nghiêm trọng hơn do thiếu người trợ giúp kịp thời, dẫn đến hiện tượng “long lie” (nằm lâu sau ngã) và làm tăng đáng kể nguy cơ tử vong, viêm phổi hít, loét tì đè và mất nước.

Việc xây dựng các hệ thống tự động phát hiện té ngã trong nhà vì vậy trở nên cấp thiết. Các hệ thống hiện có chủ yếu phát triển theo ba hướng: (i) cảm biến đeo trên người như gia tốc kế, con quay hồi chuyển; (ii) cảm biến môi trường như radar mmWave, hồng ngoại, cảm biến áp lực sàn; và (iii) hệ thống dựa trên camera thị giác kết hợp học sâu. Trong đó, hướng thị giác kết hợp ước lượng tư thế người (pose/skeleton) đang trở thành trọng tâm nghiên cứu vì vừa không yêu cầu đối tượng mang thiết bị, vừa có thể bảo toàn quyền riêng tư khi chỉ khai thác biểu diễn khung xương thay vì ảnh RGB thô.

Mặc dù đã đạt được nhiều tiến bộ, các nghiên cứu hiện nay vẫn còn một số hạn chế đáng kể: nhiều mô hình được đánh giá trên dữ liệu cũ hoặc dàn dựng, khó phản ánh đầy đủ tình huống trong nhà; Fall dễ bị nhầm với các hoạt động ADL như ngồi nhanh, nằm xuống hoặc cúi nhặt; và mô hình có thể chưa cân bằng tốt giữa độ chính xác, chi phí tính toán và khả năng triển khai. GMDCSA-24 gồm 160 clip của 4 chủ thể, trong đó có 79 mẫu Fall và 81 mẫu ADL, phù hợp để kiểm tra khả năng tổng quát hóa theo chủ thể. Kết quả công bố trên bộ dữ liệu khác không được dùng như thước đo trực tiếp cho đồ án vì khác dữ liệu và giao thức đánh giá.

Xuất phát từ nhu cầu thực tiễn và các khoảng trống nêu trên, đồ án đề xuất một hệ thống nhận diện té ngã trong nhà dựa trên phân tích chuyển động người, kết hợp trích xuất tư thế bằng pose estimator hiện đại với các mô hình học sâu chuyên biệt cho dữ liệu skeleton. Đồ án đồng thời hướng đến hai mục tiêu song hành: nâng cao độ tin cậy nhận diện và giữ được yêu cầu về riêng tư khi triển khai trong không gian sống của người dùng.

1.2 Tình hình nghiên cứu và tính mới của đề án

Phần này trình bày tổng quan các hướng nghiên cứu chính trong bài toán phát hiện té ngã, phân tích ưu – nhược điểm của từng hướng và các bộ dữ liệu tiêu biểu; từ đó xác định khoảng trống nghiên cứu và làm rõ tính mới của đề án so với các công trình đã công bố.

1.2.1 Nghiên cứu liên quan

Các nghiên cứu về phát hiện té ngã có thể được phân loại theo phương thức thu nhận dữ liệu thành bốn nhóm chính: cảm biến đeo, cảm biến môi trường, camera RGB/Depth và ước lượng tư thế người (skeleton-based). Nhóm cảm biến đeo sử dụng gia tốc kế, con quay hồi chuyển hoặc đồng hồ thông minh, đạt độ chính xác cao trong điều kiện kiểm soát nhưng bị hạn chế bởi yêu cầu người dùng phải mang thiết bị và duy trì pin.¹⁹ Nhóm cảm biến môi trường – gồm radar mmWave, cảm biến áp lực sàn, hồng ngoại – có ưu điểm giám sát không xâm lấn và bảo toàn quyền riêng tư, nhưng đòi hỏi lắp đặt phức tạp và chi phí cao.^{13,14}

Nhóm dựa trên camera RGB/Depth khai thác thông tin thị giác phong phú và không yêu cầu đeo thiết bị. Các nghiên cứu ban đầu sử dụng background subtraction, optical flow, đặc trưng hình dáng cùng CNN/3D-CNN. Tuy nhiên, cách tiếp cận này nhạy với ánh sáng, che khuất, bối cảnh nền phức tạp và đặc biệt đặt ra vấn đề riêng tư khi triển khai trong không gian sống. Chính vì vậy, xu hướng nghiên cứu gần đây chuyển mạnh sang các phương pháp dựa trên ước lượng tư thế người, trong đó video đầu vào được chuyển thành chuỗi keypoint 2D hoặc 3D biểu diễn tư thế cơ thể, giúp giảm phụ thuộc vào nền ảnh, giảm rủi ro lộ danh tính và duy trì thông tin động học quan trọng.²⁰

Trong hướng skeleton-based, Kibet và cộng sự³ sử dụng keypoint từ MediaPipe kết hợp Kalman filter và mô hình transformer trên đặc trưng vận tốc của các điểm cơ thể, đạt 97.6% accuracy và giảm rõ rệt tỉ lệ báo động giả. Egawa và cộng sự⁸ đề xuất mô hình GCN kết hợp cơ chế chú ý không-thời gian, đạt 99.00% trên ImViA. Một nghiên cứu khác kết hợp CNN và ST-GCN theo hai nhánh skeleton và motion trên URFD/UPFD với accuracy trung bình trên 94%.²⁰ Các kiến trúc SOTA cho skeleton action recognition như ST-GCN⁹, CTR-GCN¹⁰, InfoGCN¹¹ và HD-GCN cũng ngày càng được điều chỉnh cho bài toán té ngã.

Xu hướng 2025–2026 chuyển mạnh sang các kiến trúc lai và multimodal. Shin và cộng sự⁴ đề xuất khung Graph-based Spatial-Temporal Convolutional and Attention Neural

Network (GSTCAN) kết hợp Bi-LSTM với Channel Attention cho cảm biến, đạt 99.09% trên UP-Fall và 99.32% trên UR-Fall. Cùng nhóm này còn công bố kiến trúc three-stream ST-GCN với Sep-TCN, đạt tới 99.97% trên Fall-UP và 99.68% trên ImViA.⁵ Yu và cộng sự⁷ đề xuất TCNTE – kết hợp Temporal Convolutional Network với Transformer Encoder trên đầu ra của YOLOv8-pose và BoT-SORT – đạt 99.58% trên UP-Fall, 97.01% trên Le2i và 92.99% trên GMDCSA-24, đồng thời chạy được 17–19 fps trên NVIDIA Jetson Orin NX. Sykes⁶ đề xuất hệ thống pose + transformer chạy trên Raspberry Pi, hướng đến các thuộc tính “lightweight, privacy-preserving, edge-deployable”. Bên cạnh vision, hướng radar mmWave^{13,14} và Wi-Fi CSI¹² cũng nổi lên như các giải pháp thay thế camera trong không gian nhạy cảm về riêng tư.

Bảng dưới đây tổng hợp một số công trình tiêu biểu 2024–2026 gắn với bài toán phát hiện té ngã bằng phân tích chuyển động người, có vai trò làm cơ sở tham chiếu cho phần đề xuất phương pháp của đồ án.

Nhận xét tổng hợp: các nghiên cứu dùng pose và ST-GCN cho thấy biểu diễn skeleton có thể đạt hiệu quả cao mà không cần giữ ảnh RGB. Các mô hình attention và mô hình lai thường cải thiện khả năng nắm bắt quan hệ theo thời gian, nhưng đôi lại có kiến trúc phức tạp hơn, yêu cầu dữ liệu hoặc cảm biến bổ sung và khó đánh giá công bằng giữa các bộ dữ liệu. Vì vậy, đồ án chọn một kiến trúc ST-GCN gọn hơn, bổ sung motion và temporal attention ở mức vừa phải, đồng thời dùng cross-subject để kiểm tra khả năng tổng quát hóa theo người chưa thấy trong huấn luyện.

Nghiên cứu (năm)	Kiến trúc / Phương pháp	Đầu vào	Bộ dữ liệu	Kết quả tiêu biểu
Kibet et al. (2024) ³	Transformer trên keypoint + vận tốc, Kalman filter	MediaPipe pose (video)	Dataset tự thu	Acc $\approx$ 97.6%
Egawa et al. (2023) ⁸	GSTCAN – Graph Spatial-Temporal Conv + Channel Attention	Skeleton (AlphaPose)	ImViA / UR-Fall / FDD	Acc $\approx$ 99.00%
Shin et al. (2025) – Future Internet ⁴	GSTCAN (skeleton+motion) + Bi-LSTM-CA (sensor)	AlphaPose + IMU	UP-Fall / UR-Fall	99.09% / 99.32%

Nghiên cứu (năm)	Kiến trúc / Phương pháp	Đầu vào	Bộ dữ liệu	Kết quả tiêu biểu
Shin et al. (2025) – Scientific Reports ⁵	Three-Stream ST-GCN + Sep-TCN	Skeleton	ImViA / Fall-UP / FU-Kinect / UR-Fall	98.97% – 99.97%
Sykes (2025) – Health Systems ⁶	MediaPipe/OpenPose + Transformer trên Raspberry Pi	Pose	Real-world tests	Acc 98%, Sens 95.24%, F1 90.91%
Yu et al. (2025) – TCNTE ⁷	YOLOv8-pose + BoT-SORT + TCN + Transformer Encoder	Skeleton	UP-Fall / Le2i / GMDCSA-24	99.58% / 97.01% / 92.99%; 17–19 fps
Koffi et al. (2025) ¹⁵	ST-GCN + GRU + BiLSTM (impact detection)	3D Skeleton	UP-Fall 3D cải tiến	> 90%
Shen et al. (2025) ¹⁴	mmWave point cloud + LSTM-Transformer	mmWave radar	Indoor mmWave	≈ 98.75%
Cho et al. (2025) ¹²	Transformer Encoder-Decoder + GNN, tái tạo skeleton từ Wi-Fi	Wi-Fi CSI	Indoor Wi-Fi	Nhận dạng fall/HAR không cần camera
Perliński et al. (2026) ¹⁶	So sánh GCN vs YOLO trên ảnh hồng ngoại	Infrared imaging	IR dataset	Giữ riêng tư, hoạt động low-light

1.2.2 Tính mới của đề án

Từ khảo sát ở mục 1.2.1, các nghiên cứu trước đã đạt được kết quả tốt nhờ khai thác pose, đồ thị không-thời gian, attention và mô hình lai. Tuy nhiên, kết quả giữa các công trình chưa thể so sánh trực tiếp vì khác bộ dữ liệu, số chủ thể, loại cảm biến và giao thức chia tập. Trong phạm vi đề án, ba khoảng trống được chọn để kiểm chứng là: GMDCSA-24 còn ít đánh giá theo chủ thể chưa từng xuất hiện trong huấn luyện; tọa độ khớp thô chưa mô tả trực tiếp tốc độ thay đổi tư thế, góc nghiêng thân và dịch chuyển trọng tâm; và các ADL có chuyển động tương tự Fall cần được đánh giá bằng sensitivity, specificity và false alarm rate thay vì chỉ dùng accuracy.

Trên cơ sở đó, đề án không đặt mục tiêu xây dựng một kiến trúc quá lớn hoặc tuyên bố thay thế hệ thống y tế. Mục tiêu là kiểm chứng có kiểm soát xem việc bổ sung đặc trưng động học và temporal attention nhẹ vào ST-GCN có cải thiện khả năng phân biệt Fall với

ADL hay không, đồng thời giữ chi phí tính toán phù hợp với nguồn lực của đồ án.

Các đóng góp dự kiến của đồ án gồm:

- (1) Xây dựng pipeline có thể tái sử dụng cho GMDCSA-24: video được đọc tuần tự, trích xuất 33 landmark bằng MediaPipe Pose, xử lý frame thiếu pose, chuẩn hóa thành 32 frame và lưu dữ liệu trung gian để các mô hình dùng chung một đầu vào.
- (2) Xây dựng biểu diễn Motion-Enhanced Skeleton gồm vị trí tương đối, visibility, vận tốc khớp, góc nghiêng thân và độ dịch chuyển tâm hông, nhằm mô tả cả tư thế lẫn quá trình chuyển trạng thái.
- (3) Đề xuất và cài đặt ME-STGCN-TA một luồng, gồm bốn khối ST-GCN và temporal attention pooling nhẹ; mô hình hiện tại không sử dụng CNN-LSTM hoặc Transformer nhiều tầng.
- (4) So sánh Motion-SVM, Vanilla ST-GCN và ME-STGCN-TA trên cùng dữ liệu, cùng tiền xử lý và cùng giao thức Nested LOSO; thực hiện ablation study để tách ảnh hưởng của đặc trưng motion và temporal attention.

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Xây dựng và đánh giá một hệ thống nhận diện té ngã trong nhà từ chuỗi pose/skeleton trên bộ dữ liệu GMDCSA-24, có khả năng phân biệt fall với các hoạt động sinh hoạt thường ngày bằng mô hình ST-GCN gọn nhẹ được tăng cường đặc trưng chuyển động và chú ý thời gian.

1.3.2 Mục tiêu nghiên cứu cụ thể

- Khảo sát các phương pháp phát hiện té ngã dựa trên pose/skeleton, trọng tâm là ST-GCN, đặc trưng động học và cơ chế chú ý thời gian.
- Xây dựng quy trình tiền xử lý GMDCSA-24 và trích xuất pose bằng MediaPipe Pose cho toàn bộ 160 clip; dữ liệu pose gồm x, y, z và visibility, trong đó đầu vào mô hình chính sử dụng các kênh đã chọn sau bước chuẩn hóa.
- Thiết kế biểu diễn đầu vào gồm tọa độ khớp, độ tin cậy, vận tốc khớp, góc nghiêng thân và độ dịch chuyển trọng tâm.
- Đề xuất và triển khai mô hình ME-STGCN-TA với 3-4 khối đồ thị không-thời gian và temporal attention pooling cho phân loại fall/ADL.

- So sánh mô hình đề xuất với hai baseline: Motion-SVM sử dụng RBF kernel trên đặc trưng động học và Vanilla ST-GCN chỉ sử dụng tọa độ khớp.
- Đánh giá bằng cross-subject leave-one-subject-out với accuracy, precision, recall, F1-score, sensitivity, specificity, false alarm rate và confusion matrix.
- Thực hiện một ablation study, phân tích các trường hợp dự đoán sai và đo thời gian xử lý trên máy tính cá nhân; xây dựng demo nhận diện từ video có sẵn.

1.4 Đối tượng và quy mô nghiên cứu

1.4.1 Phạm vi

Phạm vi nghiên cứu chính là nhận diện té ngã trong nhà từ video đơn camera trên GMDCSA-24 gồm 160 clip, 4 chủ thể và 2 thiết lập nhà ở, với hai lớp Fall/ADL. Một số clip URFD được dùng để khảo sát demo ngoài miền dữ liệu, không dùng để huấn luyện và không được xem là bộ test độc lập vì đã được quan sát trong quá trình phát triển. Không xét ngoài trời, đám đông, đa camera, cảm biến đeo hoặc thiết bị biên chuyên dụng.

1.4.2 Đối tượng

Đối tượng nghiên cứu: (i) hành vi té ngã và các hoạt động sinh hoạt thường ngày trong bối cảnh trong nhà; (ii) chuỗi pose/skeleton gồm tọa độ ảnh 2D, chiều sâu tương đối và độ tin cậy visibility; (iii) các đặc trưng chuyển động dẫn xuất; (iv) ST-GCN và cơ chế chú ý thời gian nhẹ cho dữ liệu đồ thị không-thời gian.

1.5 Nội dung và kỹ thuật nghiên cứu

1.5.1 Nội dung nghiên cứu

- Nghiên cứu tổng quan về Human Activity Recognition, fall detection, human pose estimation, ST-GCN và temporal attention.
- Phân tích GMDCSA-24, thống nhất nhãn fall/ADL và thiết kế đánh giá cross-subject leave-one-subject-out.
- Xây dựng pipeline MediaPipe Pose, chuẩn hóa skeleton và sinh các đặc trưng động học gọn nhẹ.
- Cài đặt hai baseline Motion-SVM, Vanilla ST-GCN và mô hình đề xuất ME-STGCN-TA.
- Huấn luyện, đánh giá, thực hiện một ablation study và phân tích các ADL dễ gây nhầm.
- Xây dựng demo nhận diện trên video có sẵn, tổng hợp kết quả và hoàn thiện báo cáo.

1.5.2 Kỹ thuật nghiên cứu

Hệ thống mô hình thực nghiệm (02 baseline + 01 mô hình đề xuất)

Đồ án triển khai ba mô hình trên cùng dữ liệu GMDCSA-24, quy trình tiền xử lý và giao thức LOSO để bảo đảm so sánh công bằng:

Vai trò	Mô hình	Đầu vào / Kiến trúc chính	Mục đích so sánh
Baseline 1	Motion-SVM (RBF)	Đặc trưng vận tốc, góc thân, trọng tâm và thay đổi chiều cao	Mốc học máy truyền thống
Baseline 2	Vanilla ST-GCN	Tọa độ x, y, visibility; 4 khối ST-GCN và global average pooling	Mốc học sâu trên skeleton
Mô hình đề xuất	ME-STGCN-TA	8 kênh pose và motion; 4 khối ST-GCN và temporal attention pooling	Đánh giá đóng góp của motion và attention

- Ngôn ngữ và framework: Python 3, PyTorch; MediaPipe dùng để trích xuất pose và scikit-learn dùng để cài đặt Motion-SVM với RBF kernel.

Pose được trích xuất bằng cách đọc tuần tự toàn bộ video ở VIDEO mode với timestamp tăng dần. Notebook 01 nội suy cả tọa độ và visibility, sau đó lấy mẫu 32 mốc và lưu detection mask riêng. Bản kiểm chứng v2 giữ tọa độ đã nội suy nhưng đặt visibility bằng 0 tại mốc không phát hiện trực tiếp; thay đổi này được đánh version và phải huấn luyện lại, không áp âm thầm vào checkpoint 06.

- Đầu vào mô hình đề xuất có dạng (N, 8, 32, 33), gồm relative_x, relative_y, visibility, joint_velocity_x, joint_velocity_y, torso_angle, hip_displacement_x và hip_displacement_y. Các đặc trưng toàn thân được phát trên các node để mô hình một luồng kết hợp thông tin cục bộ và toàn thân.

Hàm mất mát là weighted cross-entropy, với trọng số tính từ các mẫu train của từng fold. Dữ liệu gồm 79 Fall và 81 ADL nên tăng thêm trọng số Fall chủ yếu thể hiện chi phí bỏ sót, không phải xử lý mất cân bằng lớp nghiêm trọng. Ablation v2 dùng cùng trọng số cân bằng lớp cho bốn biến thể; cấu hình tăng chi phí Fall được tách riêng để tránh quy toàn bộ cải thiện cho kiến trúc.

Tăng cường dữ liệu chỉ áp dụng trên tập train. Trong notebook 06, crop và nhiễu tác động lên tensor đặc trưng đã tính. Bản v2 chuyển crop, nhiễu tọa độ và lật ngang có hoán đổi trái-phải về mức pose, rồi tính lại các đặc trưng dẫn xuất. Joint dropout chỉ che các kênh cục bộ của khớp; không xóa các kênh toàn thân đã phát lap. Validation và outer-test

không augmentation.

Huấn luyện sử dụng AdamW, dropout, weight decay và seed cố định; bản 06 hiện không có learning-rate scheduler. Notebook 07 v2 đặt tối đa 50 epoch, early stopping theo validation loss và ba seed định trước. Nested LOSO dùng inner validation để chọn số epoch và ngưỡng; sau đó khởi tạo lại model, train trên cả ba subject outer-train và đánh giá subject outer-test. Không chọn seed tốt nhất để báo cáo.

- Đánh giá: bốn outer fold theo Nested LOSO, báo cáo accuracy, balanced accuracy, precision, sensitivity, specificity, F1, F2, false alarm rate và confusion matrix. Kết quả gộp 160 video là kết quả đánh giá chính; model train lại trên toàn bộ 160 video chỉ dùng cho demo và không được xem là phép đo tổng quát hóa độc lập.

CHƯƠNG 2: DỰ KIẾN CẤU TRÚC ĐỒ ÁN VÀ KẾ HOẠCH

2.1 Dự kiến cấu trúc các nội dung nghiên cứu, thực hiện trong đồ án

Chương 1: Tổng quan

Chương 1 trình bày tổng quan về bài toán, các hướng nghiên cứu và kết quả đạt được của các phương pháp trước, đồng thời phân tích hạn chế theo dữ liệu, cảm biến, khả năng tổng quát hóa và chi phí triển khai. Chương này xác định khoảng trống, đóng góp và phạm vi của đồ án.

Chương 2: Cơ sở lý thuyết

Chương 2 trình bày Human Activity Recognition và fall detection; MediaPipe Pose; biểu diễn cơ thể dưới dạng đồ thị không-thời gian; nguyên lý ST-GCN, đặc trưng động học, temporal attention và các độ đo đánh giá dành cho bài toán phát hiện té ngã.

Chương 3: Phương pháp đề xuất

Chương 3 trình bày thuật toán đề xuất theo chuỗi xử lý từ dữ liệu đến dự đoán: đọc tuần tự video và trích xuất 33 landmark bằng MediaPipe Pose; nội suy frame thiếu pose, chuẩn hóa theo tâm hông và kích thước thân, rồi resample thành 32 frame; tính tám kênh đầu vào gồm vị trí tương đối, visibility và các đặc trưng chuyển động; xây dựng đồ thị 33 khớp; đưa tensor qua bốn khối ST-GCN; spatial pooling theo khớp, temporal attention pooling theo thời gian và bộ phân loại nhị phân. Chương này cũng nêu weighted cross-entropy, augmentation chỉ trên tập huấn luyện, Nested LOSO và quy tắc chọn threshold theo validation.

Bước 1 – Chuẩn bị dữ liệu: Đọc nhãn ADL/Fall và subject từ manifest của GMDCSA-24; giữ video_id, subject và sample_index để bảo đảm các file pose, feature và fold căn chỉnh với nhau.

Bước 2 – Trích xuất pose: Đọc liên tục toàn bộ frame, sử dụng VIDEO mode và timestamp tăng dần; lưu 33 landmark với x, y, z, visibility, detection mask và detection rate.

Bước 3 – Chuẩn hóa và tạo motion: Dùng tâm hông làm gốc, chia theo kích thước thân, nội suy frame bị thiếu và resample về $T = 32$; tính vận tốc khớp, góc thân và dịch chuyển tâm hông.

Bước 4 – Xây dựng đồ thị: Mỗi landmark là một node; các cạnh biểu diễn liên kết cơ thể. ST-GCN học đồng thời quan hệ giữa các khớp và biến đổi theo thời gian.

Bước 5 – ME-STGCN-TA: Đưa tensor (N, 8, 32, 33) qua các block $8 \rightarrow 64 \rightarrow 64 \rightarrow 128 \rightarrow 128$, dùng temporal kernel 9, residual, dropout và learnable edge importance; sau spatial pooling, temporal attention gán trọng số cho các thời điểm quan trọng trước classifier.

Bước 6 – Huấn luyện và đánh giá: Dùng weighted cross-entropy, augmentation chỉ trên train và Nested LOSO. Inner validation chọn cấu hình; outer-test chỉ dùng một lần để báo cáo kết quả không bị rò rỉ.

Bước 7 – Suy luận và cảnh báo: Mô hình xuất xác suất Fall; threshold được chọn theo mục tiêu an toàn. Threshold thấp hơn có thể giảm bỏ sót nhưng làm tăng cảnh báo nhầm, nên phải báo cáo cả sensitivity và false alarm rate.

3.1 Quy trình tổng thể của phương pháp đề xuất

Pipeline gồm chuẩn bị dữ liệu offline, huấn luyện theo subject và suy luận demo. Bản 06 sử dụng feature v1 từ notebook 01; bản kiểm chứng 07 sử dụng feature v2 có điều chỉnh visibility và augmentation nhất quán. Hai phiên bản được lưu tách biệt bằng cấu hình và hash. Khi suy luận toàn clip, web giữ đúng feature v1 của checkpoint 06; cửa sổ trượt chỉ là phép thử mở rộng và chưa được suy ra là tương đương huấn luyện toàn clip.

Luồng xử lý được cố định như sau: video $\rightarrow$ chuỗi 33 landmark $\rightarrow$ pose đã làm sạch $\rightarrow$ skeleton chuẩn hóa 32 frame $\rightarrow$ đặc trưng vị trí và chuyển động $\rightarrow$ đồ thị cơ thể $\rightarrow$ các block ST-GCN $\rightarrow$ temporal attention pooling $\rightarrow$ bộ phân loại ADL/Fall. Việc tách bước trích xuất pose khỏi bước huấn luyện giúp giảm thời gian chạy lặp lại và bảo đảm ba mô hình Motion-SVM, Vanilla ST-GCN và ME-STGCN-TA sử dụng cùng một dữ liệu đầu vào đã kiểm tra.

3.2 Chuẩn bị dữ liệu và kiểm tra tính nhất quán

Dataset GMDCSA-24 được tổ chức theo subject và nhóm hành vi ADL/Fall. Manifest lưu các trường video_id, subject, label và sample_index. Sau khi kiểm tra, đồ án sử dụng 160 video của 4 subject, gồm 79 video Fall và 81 video ADL. sample_index được giữ xuyên suốt từ manifest đến pose, feature và file fold để tránh ghép nhầm nhãn với dữ liệu.

Các tệp trung gian chính gồm pose_32.npz, features_32.npz, pose_manifest.csv và cross_subject_folds.csv. File pose lưu mảng có dạng (160, 32, 33, 4), trong đó 4 thành phần của mỗi landmark là x, y, z và visibility. File features lưu các nhóm skeleton, motion, combined joint và global features; trước khi huấn luyện, các mảng được kiểm tra kích thước, NaN, Inf và sự căn chỉnh sample_index.

3.3 Trích xuất pose bằng MediaPipe Pose

Mỗi video được đọc tuần tự từ frame đầu đến frame cuối. MediaPipe Pose được chạy ở VIDEO mode và nhận timestamp tăng dần, nhờ đó bộ ước lượng có thể duy trì thông tin tracking giữa các frame liên tiếp. Với mỗi frame, hệ thống lấy tối đa 33 landmark và lưu tọa độ cùng visibility. visibility được giữ lại vì một landmark có tọa độ nhưng độ tin cậy thấp không nên được xem tương đương với landmark được phát hiện rõ.

Trong thử nghiệm ban đầu, hệ thống nhảy trực tiếp đến 32 frame mẫu bằng thao tác truy cập frame rời rạc. Cách này làm giảm hiệu quả tracking, đặc biệt ở các đoạn người cúi, nằm hoặc chuyển động nhanh; tỷ lệ phát hiện chỉ khoảng 62–66% trên video mẫu. Cách xử lý được thay thế bằng đọc toàn bộ video liên tục, phát hiện pose trước, rồi mới lấy mẫu về 32 frame. Sau thay đổi, tỷ lệ phát hiện trung bình trên toàn bộ video đạt khoảng 97,13%. Đây là lý do kỹ thuật để quy trình offline không được lấy mẫu quá sớm.

3.4 Xử lý frame thiếu và chuẩn hóa thời gian

Ở notebook 01, khi thiếu pose, các giá trị x, y, z và visibility đều được nội suy từ các frame phát hiện; ở biên, giá trị gần nhất được giữ lại. Detection mask được lưu riêng. Kiểm tra file 32 mốc cho thấy 156 mốc thiếu phát hiện trực tiếp ở 36 video. Bản v2 đặt visibility bằng 0 ở các mốc này nhưng không xóa video khỏi LOSO; tọa độ vẫn là nội suy. File 32 mốc không đủ để khôi phục toàn bộ khoảng mất pose gốc, vì vậy chưa thể khẳng định đã xử lý tốt mọi đoạn mất dài.

Sau khi làm sạch, mỗi video được resample về $T = 32$ frame bằng cách chọn các vị trí đều nhau trên toàn bộ thời lượng clip. Vì các video có FPS và thời lượng khác nhau, 32 frame ở đây là 32 mốc thời gian chuẩn hóa của một clip, không nhất thiết tương ứng với đúng 32 frame liên tiếp ngoài đời thực. Bước này tạo đầu vào cố định cho mạng và giúp các video có độ dài khác nhau được so sánh trong cùng một batch.

3.5 Chuẩn hóa không gian và tạo đặc trưng chuyển động

Để giảm ảnh hưởng của vị trí camera và khoảng cách người-camera, hệ thống chọn tâm hông làm gốc. Với frame t , vị trí tương đối của landmark v được biểu diễn bằng cách trừ tọa độ tâm hông: $p_{rel}(t,v) = p(t,v) - p_{hip}(t)$. Các tọa độ sau đó được chia cho $body_scale$ của video, được ước lượng từ khoảng cách giữa các điểm thân ổn định. Nhờ

vậy, mô hình tập trung hơn vào hình dạng và chuyển động tương đối thay vì vị trí tuyệt đối trong ảnh.

Vận tốc khớp trong implementation được tính bằng $v(t,v) = [p_rel(t,v) - p_rel(t-1,v)] / \Delta t$, với $\Delta t = duration_seconds / 31$ theo quy ước hiện tại của file feature. Hai thành phần x và y được dùng; frame đầu bằng 0. Đây là vận tốc trong hệ tọa độ ảnh đã chuẩn hóa theo body scale, không phải vận tốc vật lý m/s. Khi crop thời gian ở v2, duration của đoạn được cập nhật trước khi tính lại vận tốc.

Vector thân được tính từ tâm hông tới tâm vai; góc thân là $atan2(torso_x, -torso_y) / \pi$. Độ dịch chuyển hông là $hip(t) - hip(0)$, tính trên tọa độ ảnh chuẩn hóa, không phải sai phân giữa hai frame và không chia body scale. Ba kênh toàn thân gồm góc và hai thành phần dịch chuyển được phát lặp trên 33 khớp. Các đại lượng này phụ thuộc quy ước ảnh và không được diễn giải như đo góc 3D hoặc dịch chuyển thực ngoài không gian.

3.6 Thiết kế tensor đầu vào tám kênh

Tensor đầu vào của ME-STGCN-TA có dạng $X \in \mathbb{R}^{(N \times C \times T \times V)}$, với N là số video, C = 8 là số kênh, T = 32 là số frame và V = 33 là số landmark. Thứ tự tám kênh được cố định trong notebook và phải được giữ nguyên khi xuất model hoặc tích hợp vào demo.

Tám kênh gồm: (1) relative_x; (2) relative_y; (3) visibility; (4) joint_velocity_x; (5) joint_velocity_y; (6) torso_angle; (7) hip_displacement_x; (8) hip_displacement_y. Ba kênh torso_angle và hip_displacement được xem là đặc trưng toàn thân nhưng được phát trên các node. Vì vậy, mạng vẫn dùng một luồng dữ liệu duy nhất thay vì tách thành hai backbone độc lập.

Thiết kế này có chủ đích giữ đầu vào gọn: mô hình chính không sử dụng trực tiếp z, gia tốc, bounding-box ratio hoặc ảnh RGB. Những đại lượng đó có thể là hướng mở rộng, nhưng nếu thêm vào phải thực hiện ablation riêng để biết cải thiện đến từ nguồn nào.

3.7 Biểu diễn đồ thị và các khối ST-GCN

Cơ thể người được biểu diễn bằng một đồ thị $G = (V, E)$, trong đó V là 33 landmark và E là các liên kết giữa những khớp có quan hệ giải phẫu. Ma trận kề A mô tả các kết nối này. Self-loop được thêm vào để mỗi node giữ được thông tin của chính nó, sau đó ma trận được chuẩn hóa theo bậc node nhằm ổn định quá trình lan truyền đặc trưng.

Ở mỗi block, graph convolution tổng hợp thông tin từ node hiện tại và các node lân cận, còn temporal convolution học sự thay đổi của đặc trưng qua các frame. Do đó, một block ST-GCN không chỉ hỏi “khớp đang ở đâu” mà còn học “khớp đó thay đổi như thế nào và liên quan ra sao với các khớp khác”.

Backbone của mô hình dùng bốn block với số kênh $8 \rightarrow 64 \rightarrow 64 \rightarrow 128 \rightarrow 128$.

Temporal kernel có kích thước 9; một block giảm số bước thời gian từ 32 xuống 16 để giảm chi phí tính toán. Residual connection hỗ trợ truyền thông tin qua các block, batch normalization giúp ổn định huấn luyện, dropout hạn chế overfitting và learnable edge importance cho phép mạng điều chỉnh mức quan trọng của từng liên kết.

3.8 Temporal attention pooling

Sau các block ST-GCN, đặc trưng được pooling theo không gian trên 33 node để thu được một vector cho mỗi mốc thời gian. Thay vì average pooling tất cả mốc thời gian với trọng số bằng nhau, temporal attention tạo một điểm số cho từng mốc, chuẩn hóa các điểm số bằng softmax và dùng chúng làm trọng số khi tổng hợp.

Có thể mô tả cơ chế này bằng công thức: $e_t = w^T \tanh(W h_t + b)$, $\alpha_t = \text{softmax}(e_t)$, $z = \sum_t \alpha_t h_t$. Trong đó h_t là đặc trưng tại thời điểm t , α_t là mức chú ý và z là vector biểu diễn của toàn video. Ý nghĩa thực nghiệm là mô hình có thể tập trung hơn vào giai đoạn chuyển trạng thái, thay vì để các frame đứng yên sau khi ngã chỉ phối toàn bộ biểu diễn.

Attention hiện được tính ở 16 mốc đặc trưng sau block giảm chiều thời gian, không phải 32 giá trị tương ứng chính xác từng frame đầu vào. Các trọng số có tổng bằng 1 và được học từ dữ liệu. Nhóm đã xuất trọng số từ checkpoint đúng từng outer fold để khảo sát 20 ca báo nhâm; đó là trực quan trọng số tổng hợp, không phải bằng chứng nhân quả hay chứng minh một khớp cụ thể gây ra quyết định.

3.9 Huấn luyện, augmentation và lựa chọn operating point

Mô hình được huấn luyện bằng AdamW với learning rate, weight decay, dropout và random seed được cố định. Weighted cross-entropy được tính từ dữ liệu training của từng fold để tránh dùng thông tin của outer-test khi xác định trọng số lớp. Early stopping hoặc số epoch được quyết định từ inner validation, không quyết định bằng kết quả outer-test.

Trong phiên bản v2, temporal crop giữ 80–100% đoạn pose rồi nội suy lại 32 mốc, cập nhật thời lượng đoạn; noise và horizontal flip thực hiện trước bước tạo đặc trưng. Vận tốc, góc thân và dịch chuyển hông được tính lại sau biến đổi. Khi che khớp, chỉ các kênh cục bộ bị xóa, các kênh toàn thân giữ nhất quán. Các kiểm tra tổng hợp xác nhận tính nhất quán số học, chưa chứng minh thay đổi này cải thiện accuracy; cần kết quả ablation đầy đủ.

Ngưỡng được chọn từ inner validation, không dùng outer-test. Bản 06 đặt mục tiêu sensitivity 0,95 và specificity tối thiểu 0,60. Notebook 07 định trước mục tiêu 0,95/0,75 và báo rõ khi validation không đạt; không xem đây là cam kết chất lượng. Ba chính sách fixed, balanced và ưu tiên sensitivity dùng chung model để tách hiệu quả ngưỡng khỏi hiệu quả kiến trúc. Báo cáo đồng thời FP, FN, sensitivity, specificity, F1 và F2.

3.10 Giao thức Nested LOSO

Do dữ liệu chỉ có 4 subject, đề án không chia ngẫu nhiên theo từng video làm kết quả chính. Mỗi outer fold giữ toàn bộ video của một subject làm outer-test; ba subject còn lại tạo inner folds để chọn cấu hình. Sau khi chọn xong, mô hình được khởi tạo lại, huấn luyện trên cả ba subject của outer-train và đánh giá outer-test đúng một lần.

Giao thức này kiểm tra tình huống người mới không xuất hiện trong huấn luyện. Nó làm số lần train tăng và kết quả có thể dao động mạnh giữa các subject, nhưng đáng tin cậy hơn chia ngẫu nhiên theo video vì tránh để các video của cùng một người xuất hiện ở cả train và test.

Kết quả theo từng seed, outer subject và operating point được lưu riêng; không gộp các seed thành nhiều video độc lập. Model final 06 học đủ 160 clip và dùng threshold trung vị các fold chỉ phục vụ demo, chưa có test độc lập cho chính checkpoint đó. Các kết quả outer cũ đã được xem trong phát triển; vì vậy cần công khai lịch sử chỉnh sửa và giữ bộ dữ liệu mới chưa dùng để xác nhận, không gọi mọi lần lặp lại LOSO là test chưa từng được tham khảo.

3.11 Giả mã thuật toán

Input: tập video V và nhãn ADL/Fall. Output: xác suất Fall và nhãn dự đoán cho từng video.

1. Đọc manifest và kiểm tra video_id, subject, label, sample_index.
2. Với mỗi video, đọc tuần tự toàn bộ frame và chạy MediaPipe Pose ở VIDEO mode.
3. Lưu 33 landmark, visibility và detection mask; nội suy các frame thiếu pose.
4. Resample chuỗi về 32 frame và chuẩn hóa theo tâm hông cùng body scale.
5. Tính relative position, joint velocity, torso angle và hip displacement.
6. Ghép tám kênh thành tensor (N, 8, 32, 33).
7. Tạo graph skeleton và đưa tensor qua bốn block ST-GCN.
8. Pool theo node, tính temporal attention và tạo vector video.
9. Phân loại ADL/Fall bằng weighted cross-entropy trong quá trình huấn luyện.
10. Chọn threshold bằng validation, đánh giá outer-test và lưu xác suất, nhãn dự đoán cùng các metric.

Các bước trên mô tả thuật toán đã triển khai trong phạm vi đề án. Các hướng như thêm RGB, dùng Transformer, kết hợp cảm biến hoặc huấn luyện trên dataset lớn hơn chỉ được xem là hướng phát triển, không được trình bày như thành phần đã hoàn thành của ME-STGCN-TA hiện tại.

3.12 Phương án dự phòng về dữ liệu và pretrain

Phương án chính vẫn là huấn luyện ME-STGCN-TA trên GMDCSA-24 gồm 160 video. Chưa sử dụng pretrain hoặc dataset ngoài để train. Sáu clip URFD đã được dùng khảo sát demo/cửa sổ trượt; đây là tập phát triển ngoài miền, không phải test độc lập. Ba mốc ngã URFD hiện do AI ước lượng từ chuỗi ảnh và chưa được người gán nhãn độc lập xác nhận.

Phương án dự phòng ngắn hạn là tiếp tục sử dụng GMDCSA-24 nhưng kiểm soát overfitting bằng augmentation chỉ trên tập train, weighted cross-entropy, early stopping hoặc số epoch được chọn từ validation, regularization và threshold ưu tiên sensitivity. Đây là phương án ít rủi ro hơn vì không làm thay đổi định dạng keypoint, nhãn và giao thức đánh giá đã khóa.

Phương án mở rộng dài hạn là pretrain backbone ST-GCN trên một dataset skeleton lớn hơn về nhận dạng hoạt động người hoặc phát hiện té ngã, sau đó fine-tune trên GMDCSA-24. Quy trình dự kiến là: dataset lớn → chuẩn hóa số khớp và thứ tự khớp →

pretrain để học chuyển động cơ thể chung → thay lớp phân loại bằng hai lớp ADL/Fall → fine-tune trên GMDCSA-24 → đánh giá lại bằng Nested LOSO.

Pretrain không có nghĩa là đưa nguyên một model vào dataset mới rồi chắc chắn đạt accuracy cao hơn. Dataset pretrain phải có skeleton tương thích hoặc cần ánh xạ về 33 landmark MediaPipe; đồng thời phải thống nhất cách chuẩn hóa, số frame, visibility và các kênh motion. Nếu không kiểm soát các khác biệt này, model có thể học đặc trưng không phù hợp hoặc kết quả không còn so sánh công bằng với phiên bản huấn luyện trực tiếp.

Khi thực hiện hướng này, cần báo cáo riêng ba cấu hình: huấn luyện từ đầu trên GMDCSA-24, pretrain rồi đóng băng một phần backbone để fine-tune, và pretrain rồi fine-tune toàn bộ mạng. Chỉ kết luận pretrain có lợi nếu cải thiện được kết quả trên outer-test mà không dùng outer-test để chọn cấu hình. Phần pretrain–fine-tune vì vậy được xem là phương án dự phòng và hướng phát triển, không phải thành phần đã hoàn thành trong kết quả hiện tại.

Chương 4: Thực nghiệm

Chương thực nghiệm trình bày Nested LOSO, hai baseline và ME-STGCN-TA; kết quả v1 được giữ riêng với thí nghiệm v2. Ablation v2 gồm pose + average pooling, motion + average pooling, pose + attention và motion + attention, với cùng backbone, split, seed và chính sách chọn model. Một cấu hình tăng chi phí Fall được báo cáo riêng. Đến lần cập nhật này, notebook 07 mới được chuẩn bị và kiểm thử luồng ngắn; chưa có kết quả full ba seed để kết luận lợi ích. Báo cáo còn gồm confusion matrix, phân tích lỗi ADL, attention mô tả và benchmark trên PC.

Chương 5: Kết luận và hướng phát triển

Chương 5 tổng kết kết quả, đối chiếu với mục tiêu, thảo luận hạn chế của dữ liệu ít chủ thể và đề xuất các hướng phát triển như thử nghiệm thêm dataset, tối ưu cho thiết bị biên, nhận diện thời gian thực hoặc kết hợp thêm cảm biến.

2.2 Kế hoạch thực hiện

STT	Nội dung thực hiện	Thời gian thực hiện
1	Khảo sát tài liệu, chuẩn bị GMDCSA-24, kiểm tra nhãn và thử MediaPipe trên video mẫu.	Tuần 1 - Tuần 2
2	Trích xuất pose cho 160 video; xử lý frame thiếu, chuẩn hóa 32 frame, tạo đặc trưng và kiểm tra chất lượng keypoint.	Tuần 3 - Tuần 4
3	Xây dựng Motion-SVM và Vanilla ST-GCN; hoàn thiện giao thức Nested LOSO và các độ đo đánh giá.	Tuần 5 - Tuần 6
4	Xây dựng ME-STGCN-TA; thử đặc trưng motion, temporal attention và cấu hình ưu tiên sensitivity.	Tuần 7 - Tuần 8
5	Chạy đánh giá 4 outer fold; tổng hợp metric, confusion matrix và phân tích các trường hợp dự đoán sai.	Tuần 9 - Tuần 10
6	Thực hiện ablation study; huấn luyện model final trên toàn bộ 160 video, xuất PT/ONNX và kiểm tra suy luận.	Tuần 11 - Tuần 12
7	Hoàn thiện demo video, tổng hợp hạn chế, viết báo cáo, chuẩn bị slide và tổng duyệt bảo vệ.	Tuần 13 - Tuần 14

TÀI LIỆU THAM KHẢO

- [1] Alam, E., Sufian, A., Dutta, P., Leo, M., Hameed, I. A. (2024). GMDCSA-24: A dataset for human fall detection in videos. Data in Brief. <https://doi.org/10.5281/zenodo.12921216>
- [2] Alam, E., Sufian, A., Dutta, P., Leo, M. (2023). Real-Time human fall detection using a lightweight pose estimation technique. In ICCICBA, Springer, 30–40.
- [3] Kibet, D. et al. (2024). Sudden Fall Detection of Human Body Using Transformer Model. Sensors, 24(24), 8051.
- [4] Shin, J., Miah, A. S. M., Egawa, R., Hassan, N., Hirooka, K., Tomioka, Y. (2025). Multimodal Fall Detection Using Spatial–Temporal Attention and Bi-LSTM-Based Feature Fusion. Future Internet, 17(4), 173.
- [5] Shin, J. et al. (2025). Fall recognition using a three-stream spatio-temporal GCN. Scientific Reports.
- [6] Sykes, E. R. (2025). Next-generation fall detection: harnessing human pose estimation and transformer technology. Health Systems.
- [7] Yu, X. et al. (2025). A real-time skeleton-based fall detection algorithm based on temporal convolutional networks and transformer encoder (TCNTE). Journal of Systems and Software.
- [8] Egawa, R., Miah, A. S. M., Hirooka, K., Tomioka, Y., Shin, J. (2023). Dynamic Fall Detection Using Graph-Based Spatial Temporal Convolution and Attention Network. Electronics, 12.
- [9] Yan, S., Xiong, Y., Lin, D. (2018). Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition. AAAI.
- [10] Chen, Z., Li, S., Yang, B., Li, Q., Liu, H. (2021). Channel-wise Topology Refinement Graph Convolution for Skeleton-Based Action Recognition (CTR-GCN). ICCV.

- [11] Chi, H.-G. et al. (2022). InfoGCN: Representation Learning for Human Skeleton-based Action Recognition. CVPR.
- [12] Cho, Y., Motta, E., Nocentini, O. et al. (2025). Wi-Fi based Human Fall and Activity Recognition using Transformer-based Encoder–Decoder and Graph Neural Networks. IEEE Sensors Journal.
- [13] Chen, H. H. et al. (2026). Millimeter-wave technology for multi-person fall detection.
- [14] Shen, Y. et al. (2025). Fall detection system based on LSTM-Transformer and millimeter-wave radar for indoor fall detection. SPIE Proc. 13560.
- [15] Koffi, T. Y., Hindawi, M., Dupuis, Y. (2025). Impact Detection in Fall Events: Leveraging Spatio-Temporal Graph Convolutional Networks and Recurrent Neural Networks Using 3D Skeletons Data.
- [16] Perliński, K. et al. (2026). Human Fall Detection with Infrared Imaging: A Comparison of GCN and YOLO Approaches. Sensors, 26(9), 2794.
- [17] Jishnuraj, K. et al. (2026). Fall detection among elderly persons using FallCNN and transfer learning. Frontiers in Artificial Intelligence.
- [18] Zhang, Z., Ni, H. (2025). A Lightweight Skeleton-Based Fall Detection Framework Using Multi-Dimensional Attention Mechanisms. INNO-PRESS JAAI.
- [19] Karim, M. et al. (2025). Next generation human action recognition: A comprehensive review of state-of-the-art signal processing techniques. IEEE Access.
- [20] Gaya-Morey, F. X., Manresa-Yee, C., Buades-Rubio, J. M. (2024). Deep learning for computer vision based activity recognition and fall detection of the elderly: a systematic review. Applied Intelligence.